

# SVM

## Mathematical Modeling

Prof. Dr. Jingzhi Li

Department of Mathematics,  
Southern University of Science and Technology

2025 Spring



## ① SVM

## ② SVM 的实现

## ③ 课堂练习

# ① SVM

## ② SVM 的实现

## ③ 课堂练习


# 概述

SVM (Support Vector Machine) 中文名为支持向量机，是一种有监督的学习模型。

- SVM 常用于分类，模式识别和回归

# SVM 的工作原理


SVM 的主要思想是找到一个超平面，使得它能够尽可能多地将两类数据点正确分开，同时使分开的两类数据点距离超平面最远。



- 平面 A 更靠近蓝色球
- 平面 B 更靠近红色球
- 相比于 A 和 B，平面 C 的鲁棒性更强

# 线性可分

- 定义:  $D_0$  和  $D_1$  是  $n$  维欧氏空间中的两个点集。如果存在  $n$  维向量  $\omega$  和实数  $b$ , 使得所有属于  $D_0$  的点  $x_i$  都有  $\omega^T x_i + b > 0$ , 而对于所有属于  $D_1$  的点  $x_j$  则有  $\omega^T x_j + b < 0$ , 则我们称  $D_0$  和  $D_1$  线性可分。
- 直观理解: 在  $n$  维空间上, 两类点被一个超平面完全分开叫做线性可分。




# 最大间隔超平面

为了使找到的超平面更具有鲁棒性，我们需要寻找最佳超平面，以最大间隔把两类样本分开的超平面，称为最大间隔超平面。

- 两类样本分别分割在该超平面的两侧
- 两侧距离超平面最近的样本点到超平面的距离被最大化

# 支持向量

样本中距离超平面最近的一些点称为支持向量 (Support Vector)





# SVM 的数学形式

在  $n$  维空间中，超平面可以用下面的线性方程来描述：

$$\omega^T x + b = 0$$

其中  $\omega, x \in R^n$ 。

任意点  $x = (x_1, x_2 \dots x_n)$  到直线  $\omega^T x + b = 0$  的距离为：

$$\frac{|\omega^T x + b|}{\|\omega\|}$$

其中  $\|\omega\| = \sqrt{\omega_1^2 + \dots \omega_n^2}$ 。

假设支持向量到超平面的距离为  $d$ ，则其他点到超平面的距离大于  $d$ ，于是我们有

$$\begin{cases} \frac{\omega^T x + b}{\|\omega\|} \geq d & y = 1 \\ \frac{\omega^T x + b}{\|\omega\|} \leq -d & y = -1 \end{cases}$$

即

$$\begin{cases} \frac{\omega^T x + b}{\|\omega\|d} \geq 1 & y = 1 \\ \frac{\omega^T x + b}{\|\omega\|d} \leq -1 & y = -1 \end{cases}$$

$\|\omega\|d$  恒为正数，为了方便优化，我们可以将其省略：

$$\begin{cases} \omega^T x + b \geq 1 & y = 1 \\ \omega^T x + b \leq -1 & y = -1 \end{cases}$$

将两个方程合并后, 对于数据集  $\mathcal{D} = \{(x_1, y_1), \dots, (x_m, y_m)\}$ , 其中  $x_i \in \mathbb{R}^n$  是输入向量,  $y_i \in \{-1, 1\}$  是输入数据的分类, 我们有

$$y_i (\omega^T x_i + b) \geq 1$$

接着我们要找到最大间隔超平面, 简化后得到 SVM 的最优化问题

$$\begin{aligned} \min_{\omega, b} \quad & \frac{1}{2} \|\omega\|^2 \\ \text{s.t.} \quad & y_i (\omega^T x_i + b) \geq 1 \end{aligned}$$

# 引入 Lagrange 乘子

构造拉格朗日函数

$$\min_{\omega, b} \max_{\lambda} L(\omega, b, \lambda) = \frac{1}{2} \|\omega\|^2 + \sum_{i=1}^m \lambda_i \left[ 1 - y_i (\omega^T x_i + b) \right]$$

其中  $\lambda_i \geq 0$  为 Lagrange 乘子。利用强对偶性转化得

$$\min_{\omega, b} \max_{\lambda} L(\omega, b, \lambda) = \max_{\lambda} \min_{\omega, b} L(\omega, b, \lambda)$$

对参数  $\omega$  和  $b$  的偏导置零, 得

$$\sum_{i=1}^m \lambda_i x_i y_i = \omega$$

$$\sum_{i=1}^m \lambda_i y_i = 0$$

回代得到原问题的 Lagrange 对偶问题

$$\begin{aligned} \max_{\lambda} \quad & \sum_{j=1}^m \lambda_j - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \lambda_i \lambda_j y_i y_j (x_i \cdot x_j) \\ \text{s.t.} \quad & \sum_{i=1}^m \lambda_i y_i = 0 \quad \lambda_i \geq 0 \end{aligned}$$

## KKT 条件

求解上述最优化问题后得到最优解  $\lambda_i^*$ ，计算得到最终模型

$$f(x) = \omega^T x + b = \sum_{i=1}^m \lambda_i^* y_i x_i^T x + b$$

注意到该优化问题为凸优化问题，且满足 Slater 条件，即存在严格可行解。那么上述求解过程需满足 KKT 条件


$$\begin{cases} \lambda_i \geq 0 \\ y_i f(x_i) - 1 \geq 0 \\ \lambda_i (y_i f(x_i) - 1) = 0 \end{cases}$$

KKT 条件是一个非线性优化问题能有最优解法的充分必要条件。

于是, 对于任意样本  $(x_i, y_i)$ , 总有  $\lambda_i^* = 0$  或  $y_i f(x_i) = 1$ , 若  $\lambda_i^* = 0$ , 则对应样本点不会在最终模型的求和中出现。若  $\lambda_i^* > 0$ , 则有  $y_i f(x_i) = 1$ , 即该样本点是一个支持向量。我们会得到 SVM 的一个重要的性质: 训练完成后, 大部分样本点不需要保留, 最终模型只与支持向量有关。

# 软间隔


如果数据不是完全线性可分的，例如



此时我们可以适当放宽约束条件，允许个别点出现在间隔层里面，即不满足


$$1 - y_i (\omega^T x_i + b) \leq 0$$

我们称其称为软间隔。





为了度量软间隔软的程度，我们为每个数据点引入松弛变量  $\xi_i$ ，令  $\xi_i \geq 0$ ，且  $1 - y_i (\omega^T x_i + b) - \xi_i \leq 0$ 。对应如下图所示：



增加软间隔后我们的优化目标变为：

$$\begin{aligned} \min_{\omega, b} \quad & \frac{1}{2} \|\omega\|^2 + C \sum_{i=1}^m \xi_i \\ \text{s.t.} \quad & g_i(\omega, b) = 1 - y_i (\omega^T x_i + b) - \xi_i \leq 0 \\ & \xi_i \geq 0 \end{aligned}$$

其中  $C$  是惩罚系数，代表对分类器中存在异常点的容忍程度。

## 构造拉格朗日函数

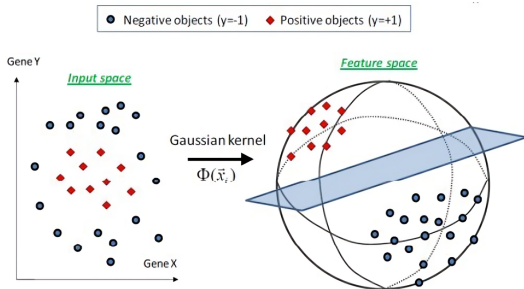
$$\begin{aligned}
\min_{\omega, b, \xi} \max_{\lambda, \mu} L(\omega, b, \xi, \lambda, \mu) &= \frac{1}{2} \|\omega\|^2 + C \sum_{i=1}^m \xi_i \\
&+ \sum_{i=1}^n \lambda_i \left[ 1 - \xi_i - y_i (\omega^T x_i + b) \right] - \sum_{i=1}^n \mu_i \xi_i \\
&\text{s.t.} \quad \lambda_i \geq 0 \quad \mu_i \geq 0
\end{aligned}$$

经过转化后得到

$$\begin{aligned}
\max_{\lambda} &\left[ \sum_{j=1}^n \lambda_j - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j (x_i \cdot x_j) \right] \\
\text{s.t.} &\sum_{i=1}^n \lambda_i y_i = 0, \quad \lambda_i \geq 0, \quad C - \lambda_i - \mu_i = 0
\end{aligned}$$

# 核函数

对于数据点完全线性不可分的情况，我们引入核函数  $k(x, y) = (\phi(x), \phi(y))$  将低维线性不可分的数据点映射到高维空间中，使其变得线性可分。



## 常见的核函数

- 线性核函数

$$k(x_i, x_j) = x_i^T x_j$$

- 多项式核函数

$$k(x_i, x_j) = (x_i^T x_j)^d$$

- 高斯核函数

$$k(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|}{2\delta^2}\right)$$

- sigmoid 核函数

$$k(x_i, x_j) = \tanh(\beta x_i^T x_j + c)$$

可以证明, 带有 sigmoid 核的 SVM 等价于两层的多层感知机

# 用 SVM 解决多分类问题

- **一对多法**：假设我们要将数据集分为 A、B、C、D 四类，那么我们可以先把其中的一类作为分类 1，其他类统一归为分类 2。这种方法，针对 K 个分类，需要训练 K 个分类器。
  - 分类速度较快，但训练速度较慢
  - 负样本数量远大于正样本数量，会造成样本不对称的情况
  - 如果增加新的分类，需要对分类器重新构造
- **一对一法**：在任意两类样本之间构造一个 SVM，这样针对 K 类的样本，就会有  $C(k, 2)$  类分类器。当对一个未知样本进行分类时，每一个分类器都会有一个分类结果，即为 1 票，最终得票最多的类别就是整个未知样本的类别。
  - 如果新增一类，只需要训练和新增这一类样本的分类器
  - 分类器的个数与 K 的平方成正比，当 K 较大时，训练和测试的时间会比较慢

# SVM 的优缺点

- 优点：
  - 有严格的数学理论支持，可解释性强
  - 采用核技巧之后，可以处理非线性分类或回归任务
  - 样本量不大时，分类准确率高，泛化能力强
  - 解决高维特征的分类问题和回归问题很有效，在特征维度大于样本数时依然有很好的效果
- 缺点：
  - S 在样本量非常大，核函数映射维度非常高时，计算量过大，不太适合使用
  - 非线性问题的核函数的选择没有通用标准，难以选择一个合适的核函数
  - SVM 对缺失数据敏感

① SVM

② SVM 的实现

③ 课堂练习

# MATLAB 中关于 SVM 的函数和参数

常用函数：

- `fitcsvm`：训练用于二分类的 SVM 分类器
- `fitcececoc`：训练用于多分类的 SVM 分类器
- `predict`：预测

`fitcsvm` 的常用参数：

- `KernelFunction`：核函数类型
- `BoxConstraint`：惩罚参数，控制软间隔
- `Standardize`：是否对特征进行标准化



# 分类学习器-SVM

可以使用分类学习器 APP 实现 SVM

支持向量机



线性 SVM



二次 SVM



三次 SVM



精细高斯  
SVM



中等高斯  
SVM



粗略高斯  
SVM



全部 SVM



可优化 SVM

# 利用 sklearn 实现 SVM

- 导入 SVM 工具包: `from sklearn import svm`
- 直接导入 SVM 分类器: `from sklearn.svm import svc`
- 创建 SVM 模型: `model = svc()`
  - 参数 `kernel`: 指定核函数类型
  - 参数 `C`: 惩罚项系数
  - 参数 `gamma`: 高斯核函数系数
- 线性 SVM 分类器: `LinearSVC`
  - 使用线性核函数, 不能选择其他核函数
  - 在线性可分的情况下效率更高
- SVC 实现多分类任务
  - decision function shape='ovo': 一对一
  - decision function shape='ovr': 一对多

① SVM

② SVM 的实现

③ 课堂练习

# 用 SVM 进行乳腺癌检测

数据集 `data.csv` 来自美国威斯康星州的乳腺癌诊断数据集。医疗人员采集了患者乳腺肿块经过细针穿刺 (FNA) 后的数字化图像，并且对这些数字图像进行了特征提取，这些特征可以描述图像中的细胞核呈现。肿瘤可以分成良性和恶性。

数据表一共包含了 32 个字段，代表的含义保存在字段含义.jpeg 中。mean 代表平均值，se 代表标准差，worst 代表最大值（3 个最大值的平均值）。每张图像都计算了相应的特征，得出了这 30 个特征值（不包括 ID 字段和分类标识结果字段 diagnosis），实际上是 10 个特征值（radius、texture、perimeter、area、smoothness、compactness、concavity、concave points、symmetry 和 fractal dimension mean）的 3 个维度，平均、标准差和最大值。这些特征值都保留了 4 位数字。字段中没有缺失的值。在 569 个患者中，一共有 357 个是良性，212 个是恶性。我们的目标是生成一个乳腺癌诊断的 SVM 分类器，并计算这个分类器的准确率。